

이 페이지는 링크가 있는 모든 사용자에게 표시됩니다. ⓘ



260904_회의 내용

▶ 금일 목표

🗣️ 오전 회의

- 아키텍처 설계를 잘하자...!!

받으신 피드백의 핵심은 "채점 시점마다 수백 페이지짜리 원문 텍스트 전체를 실시간 검색 (Retriever)하는 비용/속도 지연(Latency) 문제를 줄이자"는 것입니다.

즉, [1단계: 사전에 필요한 정보만 추출/요약하여 정형 DB 구축] > [2단계: 채점 시에는 요약된 정형 DB만 읽어서 LLM으로 채점/출력] 파이프라인 구조를 제안받으신 상황입니다.

피드백받으신 구조의 핵심 흐름

[원문 문서 (PDF/보고서)] | ▼ (1회성 전처리 Batch: 기준표 질문/항목 단위로 타겟팅 파싱) [요약/추출된 정형 DB (DB/Table)] → "통계/요약 데이터만 저장" | ▼ (실시간 채점 시: 문서 검색 생략, 필요 텍스트만 빠른 Exact Lookup) [LLM 채점 및 결과 출력]

현 방식 vs 피드백받은 방식 비교

구분	현재 구현 방식 (Full RAG)	피드백받은 방식 (Pre-parsed / Pre-summarized DB)
작동 구조	채점할 때마다 원문 벡터 DB 전체에서 하이브리드 검색 후 채점	기준표 항목(91개)에 맞춰 보고서에서 해당 요약 텍스트만 미리 파싱해서 정형 DB에 보관 후 채점
속도 (Latency)	🐢 느림 (91개 항목 $\times$ 임베딩/BM25 검색 시간 소요)	⚡ 매우 빠름 (미리 요약된 정형 DB 레코드만 가져오므로 즉시 처리)
토큰/비용	💰 큼 (검색된 길고 정제되지 않은 문단들을 매번 LLM에 전달)	💰 적음 (정제/요약된 핵심 정보만 프롬프트에 넣으므로 비용 절감)
구현 난이도	상대적으로 단순 (문서 잘라서 임베딩만 해주면 됨)	전처리 단계에서 91개 항목별 정보를 정확하게 요약/추출해 두는 ETL 로직 필요

피드백 적용 시 제안하는 고도화 방향

1. 사전 전처리(Offline Processing) 레이어 추가

- 문서가 새로 들어오면 91개 K-ESG 항목(또는 영역)별로 필요한 핵심 숫자, 사실, 관련 단락만 추출/요약하는 Batch 작업을 미리 실행합니다.
- 예: [기업: SK하이닉스, 연도: 2024, 항목: E-1-1] -> 요약 근거: "2024년 온실가스 배출량 총 4,500천tCO2eq (전년 대비 3% 감축)"

2. 요약/통계 정형 DB(RDB 또는 Structured JSON) 구축

- 이렇게 파싱/요약된 데이터만 데이터베이스(MySQL, PostgreSQL, 또는 Pandas DataFrame)에 저장합니다.

3. 실시간 채점 엔진 단순화

- 실시간 채점 시에는 Chroma DB 등 비정형 벡터 검색 과정을 거치지 않고, 정형 DB에서 해당 항목의 요약 근거만 키(Key)값으로 읽어와 LLM에 전달합니다.
- 검색 시간이 소요되지 않아 채점 속도가 획기적으로 줄어듭니다.

언급하신 용어는 데이터베이스(DB) 분야에서 대용량 데이터를 저장할 때 사용하는 LOB(Large Object) 데이터 타입의 종류입니다. 정확한 명칭은 CLOB과 BLOB (또는 RLOB)입니다.

현재 구축 중이신 ESG 채점 파이프라인(텍스트 파싱, 정형/비정형 DB 구축)과 관련해서 아래와 같이 구분됩니다.

1. 주요 LOB 데이터 타입 종류

- CLOB (Character Large Object)
 - 정의: 매우 긴 문자열(텍스트) 데이터를 저장하는 타입입니다.
 - 용도: 수십~수백 페이지 분량의 ESG 지속가능경영보고서 원문, 사업보고서 텍스트, LLM 프롬프트/응답 전문, 요약문 등을 정형 DB(RDB) 테이블의 한 컬럼에 보관할 때 사용합니다.
 - 특징: 텍스트 인코딩(UTF-8 등)을 지원하며 문자 단위로 관리됩니다.
- BLOB (Binary Large Object)
 - 정의: 이미지, PDF, 압축파일, 오디오 등 이진(Binary) 데이터를 그대로 저장하는 타입입니다.
 - 용도: 파싱하기 전 원본 PDF 파일 자체, 추출된 이미지/그래프 파일 등을 DB에 저장할 때 씁니다.
- RLOB / LOB (Ref/Relative or General Large Object)
 - 일반적인 LOB(Large Object) 범주를 의미하거나, 특정 DB 솔루션(예: CUBRID 등)에서 포인터/참조형으로 대용량 객체를 다룰 때 부르는 명칭입니다.

2. 현재 ESG 프로젝트(정형 DB 고도화)에서의 활용 방안

피드백받으신대로 "보고서에서 필요 내용만 파싱/요약하여 정형 DB에 담아두는 방식"으로 전환하실 때 다음과 같이 활용할 수 있습니다.

1. 일반 컬럼 (VARCHAR / TEXT)

- 요약된 ESG 근거 문장, 숫자로 된 통계 데이터, 배점 등 (길이가 짧은 데이터)

2. CLOB 컬럼

- 91개 K-ESG 항목별로 추출한 원문 절편(Chunk) 데이터나 LLM 요약 텍스트 전문처럼 길어질 수 있는 비정형 텍스트 보관용

3. BLOB 컬럼

- 보고서 내 표(Table)나 그래프를 이미지 형태로 저장할 필요가 있을 때 활용

실시간(Real-Time) 서비스와 배치(Batch) 서비스는 데이터 처리 방식과 응답 속도, 실행 시점에 따라 구분되는 대표적인 두 가지 시스템 처리 방식입니다.

1. 실시간 서비스 (Real-Time Service)

사용자의 요청이나 데이터가 발생했을 때 **즉각(수 밀리초~수 초 이내)** 처리하여 **그 결과를 바로 반환**하거나 반영하는 방식입니다.

- **주요 특징:**
 - **낮은 지연 시간(Low Latency):** 데이터 처리 및 응답 속도가 매우 빠릅니다.
 - **대화형(Interactive):** 사용자나 이벤트와 실시간으로 주고받는 구조입니다.
 - **작은 데이터 단위:** 대량의 데이터보다는 개별 요청(건별 데이터)을 빠르게 처리하는 데 적합합니다.
 - **대표 사례:**
 - 온라인 결제 및 송금 시스템
 - 메신저/채팅 앱, 실시간 알림 서비스
 - 주식/가상자산 실시간 거래 및 체결 시스템
 - 웹/앱 로그인 및 회원가입 처리
-

2. 배치 서비스 (Batch Service)

데이터를 즉시 처리하지 않고, **일정한 기간 동안 모아두었다가 일괄적으로 한 번에 처리**하는 방식입니다. 주로 시스템 사용량이 적은 야간이나 정해진 주기에 수행됩니다.

- **주요 특징:**
 - **높은 처리량(High Throughput):** 대량의 데이터를 한 번에 효율적으로 처리하는 데 최적화되어 있습니다.
 - **비대화형(Non-interactive):** 정해진 스케줄러(Cron 등)나 이벤트Trigger에 의해 사람의 개입 없이 자동으로 실행됩니다.
 - **자원 효율성:** 시스템 부하가 적은 시간에 대규모 컴퓨팅 자원을 할당하여 처리할 수 있습니다.

- 대표 사례:
 - 은행의 일일 마감 및 이자 계산, 월별 계좌 명세서 생성
 - 정기 급여 계산 및 자동 이체
 - 일일/월별 매출 집계 및 통계 리포트 생성
 - 대용량 데이터베이스 백업 및 로그 정리

요약 및 핵심 비교

구분	실시간 서비스 (Real-Time)	배치 서비스 (Batch)
처리 시점	데이터/요청 발생 직후 즉시	정해진 주기(매일 야간, 매주 등) 또는 일정량 축적 시
응답 속도	수 밀리초 ~ 수 초 이내	수 분 ~ 수 시간 (대용량 처리)
처리 단위	개별 트랜잭션/요청 단위	대량의 데이터 묶음 (Bulk Data)
주 목적	빠른 사용자 경험 제공, 즉각적인 상태 변경	대규모 데이터 처리의 효율성 증대, 자원 최적화
주요 활용	결제, 채팅, 주식 거래, 검색	정산, 통계 집계, 백업, 리포트 생성

- PRD (사람/사용자 관점): "사람(사용자/비즈니스)이 무엇을 원하는가?"를 정의합니다. PM이나 기획자가 고객의 문제, 필요한 기능, 비즈니스 목표를 바탕으로 정성적·기능적 요구사항을 작성합니다.
- TRD (시스템/기술 관점): "PRD에서 정의한 내용을 기술적으로 어떻게 구현할 것인가?"를 정의합니다. 개발자나 엔지니어가 PRD를 전달받아 DB 설계, API 명세, 시스템 아키텍처 등 실제 개발이 가능한 수준의 기술 명세로 번역하여 작성합니다.

흐름 요약

1. PRD 작성: "사용자가 버튼을 누르면 결제가 완료되고 이메일 영수증이 발송되어야 한다." (PM/기획자)
2. TRD 작성: "PRD의 결제 요청을 처리하기 위해 PG사 API를 연동하고, DB의 `orders` 테이블 상태값을 `PAID` 로 변경하며, Kafka 메세지 큐를 통해 이메일 발송 서비스 (SMTP)를 호출한다." (개발자/아키텍트)

결과적으로 PRD가 입력이 되어 TRD라는 출력이 나오는 관계입니다.

구분	RDB (관계형 DB)	Vector DB (벡터 DB)
주요 저장 대상	정형 데이터 (텍스트, 숫자, 날짜 등)	고차원 임베딩 벡터 (비정형 데이터의 의미 표현)
데이터 형태	표 형태 (Table: Row & Column)	고차원 숫자 배열 (Dense Vector)
검색 기준	키워드/조건 정확도 (Exact Match)	의미적 유사도 (Similarity Match)
검색 연산	B-Tree 인덱스, SQL 필터링	ANN 인덱스 (HNSW, IVF 등), 거리 계산
주요 유스케이스	결제, 계정 관리, ERP, 서비스 DB	RAG (AI 대화 맥락 보완), 상품 추천, 이미지 검색

보고서 > 기준으로 넣기

💡 요약

벡터 DB에서 문맥과 근거(비정형 데이터)를 찾고, LLM이 이를 판단한 뒤, **정형 DB(엑셀 기준표)**의 점수 매핑 규칙에 맞춰 최종 ESG 점수를 산출하는 구조입니다.

녹음 회의록

- 안건1. 서비스/기술 아키텍처 우선 확정 및 데이터 저장 전략 재정의
"서비스 흐름(PRD)과 아키텍처를 먼저 확정된 뒤, 벡터 DB는 검색용으로만 쓰고 채점 결과는 정형 DB를 마스터로 저장·활용할 것"
의사결정자 코멘트
아키텍처 부재에 대한 리스크 경고 및 선행 산출물 요구
- 설계 문서 없이 구현부터 진행한 상태로 판단하며, 아키텍처 오류 시 임베딩 재작업 등 대규모 리워크 리스크가 큼
- 벡터 DB 구축·개별 채점 작업보다 "전체 큰 그림(데이터 입력→검색/채점→저장→서비스 제공)"을 먼저 문서/그림으로 확정할 것
- 중요한 프로세스는 단계별 플로우차트로 정의하고, 그 문서를 기준으로 구현 순서를 재정렬할 것
벡터 DB와 정형 DB의 역할 분리(이원화) 방향 제시
- 유사도 검색으로 한 번 추출·채점된 결과는 정형 DB에 저장하여 이후 서비스(조회/챗봇/리포트)에서 재사용할 것
- 챗봇 요청 시 "정형 DB 우선 조회 → 없을 때만 벡터 DB 유사도 검색 → 채점 수행 후 정형 DB 적재" 구조로 설계할 것

- 정제된 메타/등급/시가총액 등 구조화 데이터는 벡터 DB에 넣지 말고 정형 DB로 관리할 것
- 벡터 DB는 자연어 원문/근거 문장 검색이 필요한 경우에 한해 중간 단계로 활용할 것
서비스 운영 방식(실시간 vs 배치) 및 휴먼 검수 포함 설계 지시
- 휴먼 검수가 필요한 항목은 프로세스 분기로 명확히 설계할 것(자동 완료 vs 사람 확인 필요)
- 실시간 서비스(업로드 후 즉시 채점)와 배치 서비스(야간 처리) 두 시나리오를 모두 놓고 단계/상태(업로드→채점→검수→완료)를 정의할 것
안건 1 관련 논의
- Q: 벡터 DB 기반 채점에서 유사도/BM25 검색을 위한 입력 프롬프트가 무엇인지, 채점 기준표에서 어떤 값을 추출해 쿼리로 쓰는지?
 - A: 진단 항목명/세부 기준의 키워드를 프롬프트로 사용하고, 댄스(임베딩 코사인) 상위 결과와 BM25 결과를 통합해 근거 청크를 모은 뒤 단계 점수를 산정함
- Q: 벡터 DB 검색 결과를 채점 단계로 연결할 때, 단계 판정은 어떤 방식으로 수행되는지?
 - A: 단계별 키워드/표현을 근거 페이지(최소 3페이지 이상)에서 다수 확보하고, 근거 요약·핵심 문구를 함께 산출해 단계 점수를 결정함
- Q: 법령 위반 여부 판단의 입력 근거는 무엇인지?
 - A: 사업보고서 내 과태료/법령 위반 관련 기사를 근거로 사용하되, 감점/위반 유형은 근거 불충분 시 "휴먼 추가 검수 필요"로 플래그 처리함
안건2. 채점 품질 이슈(가중치·수치·표·수식) 개선을 위한 프롬프트/파싱 보강
"키워드 확장 같은 로우레벨 튜닝은 지양하고, 리즈닝 기반 전처리·표(OCR) 처리 보강으로 채점 품질을 개선할 것"
의사결정자 코멘트
품질 저하 원인 가설 및 개선 방향
- 환경/사회 점수 저하는 수치·표·수식이 파싱/전달 과정에서 누락·왜곡되었을 가능성이 큼
- 가중치 미반영, 표 깨짐 등 "특정 케이스"를 식별해 원인별로 보완할 것
프롬프트 전략 지시(단계적 프롬프팅)
- 채점 전에 보고서 원문을 기준에 맞게 "변환/정규화"하도록 1차 프롬프트를 수행하고, 변환 결과를 기반으로 2차 채점을 수행하는 단계적 프롬프팅을 적용할 것
- 수치 표기(만원/10,000원/1만원 등)처럼 표현이 달라도 동일 의미로 리즈닝하도록 프롬프트에 명시할 것
- 업종 확장 가능성을 고려해 과도한 키워드 수작업 튜닝으로 범용성을 훼손하지 말 것
표 인식(테이블) 처리 보강 지시

- 테이블 OCR을 적용해 표를 HTML 또는 마크다운 형태로 보존하고, LLM에 전달 시 표 구조가 깨지지 않도록 할 것
- 현재 파싱 로직에서 "표가 포함된 구간"의 출력 형태를 점검하고, 표가 깨지는 구간은 별도 포맷으로 재저장/재전달하는 방식을 검토할 것
안건 2 관련 논의
- Q: 환경/사회 점수 저하가 수식/표 파싱 문제인지, 실제로 어떤 형태의 문항에서 문제가 발생하는지?
 - A: 가중치·산출식이 포함된 복합 문항에서 점수 산정이 누락되거나, 수치 단위/정규화 미흡으로 불일치 감점이 발생함
- Q: 검색 결과의 변동성(유사도 검색 랜덤성)을 어떻게 통제하고 있는지?
 - A: BM25를 앙상블로 넣어 변동성을 줄이고, 컨피던스 임계값(약 0.6대)을 두되 과도 상향 시 검색 누락 리스크가 있음
안건3. 뉴스/홈페이지 크롤링 추진 리스크 관리 및 플랜B 결정
"뉴스·홈페이지 수집은 1~2개 기업으로 POC 후 확대 여부를 즉시 결정하고, 불확실하면 즉시 중단해 플랜B(수작업 입력 기반)로 전환할 것"
의사결정자 코멘트
크롤링 리스크 평가 및 우선순위 조정
- 홈페이지는 기업별 구조가 달라 난이도·불확실성이 크며, 일정 리스크가 큰 영역으로 판단함
- 공개 정보가 없는 기업까지 무리하게 포함하지 말고, 공개 자료 기반으로 가능한 범위에서 한계를 인정할 것
실행 지시: POC 기반 Go/Stop 및 플랜B 전환
- 전체 기업을 한 번에 크롤링하지 말고 1~2개 기업으로 POC를 먼저 수행할 것
- POC 결과가 "확대 가능"이면 범위를 넓히고, 불가능하면 즉시 중단 후 플랜B로 전환할 것
- 플랜B는 플랫폼에서 항목별 체크(직접 입력/클릭)로 점수를 산정하는 방식으로 준비할 것
- 크롤링/플랫폼/채점/서비스화 등 병렬 과제가 존재하므로 역할 분담을 전제로 추진할 것
안건 3 관련 논의
- Q: 크롤링 대상 기업 수가 어느 정도인지?
 - A: 보고서 3종 확보 기업은 54개 수준이며, 보고서 미확보 기업은 약 50개 내외로 추정됨

- Q: 공개 정보가 거의 없는 기업까지 과거 뉴스로라도 반영해야 하는지?
 - A: 공개 정보가 없는 경우는 현 단계에서 한계로 인정하고, 향후 기업이 최소 정보 입력을 제공하는 방식(직접 체크 입력)으로 대응하는 것이 현실적임
- 안건4. 일정/커뮤니케이션: 중간 아키텍처 공유 및 14~15일 검수 일정 확정
- "아키텍처 자료를 사전 공유하고, 14~15일에 오프라인 검수를 진행하며 필요 시 온라인 추가 미팅을 잡을 것"
- 의사결정자 코멘트
- 일정 확정 및 진행 방식
- 1011일은 일정상 어려우며, 1415일은 가능하다고 확정함
- 아키텍처 이미지를 사전 공유하면, 저녁 시간대 온라인으로 별도 미팅을 추가로 잡아 검토할 것
- 안건 4 관련 논의
- Q: 14~15일에 방문 검수가 가능한지?
 - A: 14~15일 가능하며, 사전 자료 공유 시 온라인 추가 검토도 병행 가능함